

# Prepoznavanje Ugođaja Pjesama

## Strojno učenje - projektni prijedlog

Marija Gegić i David Mrkoci

27. travnja 2022.

# Sadržaj

<b>1</b>	<b>Opis problema</b>	<b>2</b>
<b>2</b>	<b>Cilj i hipoteze istraživanja</b>	<b>2</b>
2.1	Zašto baš ovakva klasifikacija? . . . . .	3
<b>3</b>	<b>Pregled dosadašnjih istraživanja</b>	<b>3</b>
<b>4</b>	<b>Dataset i metodologija</b>	<b>3</b>
4.1	Dataset . . . . .	3
4.2	Metodologija . . . . .	5
<b>5</b>	<b>Literatura</b>	<b>7</b>

# 1 Opis problema

Kroz ovaj projekt proučavat ćemo problem klasifikacije pjesama prema ugođaju. Želimo razviti model koji će nam omogućiti da klasificiramo ugođaj neke proizvoljne pjesme, pri čemu se ograničavamo na pjesme dostupne na platformi Spotify.

Pjesme ćemo dijeliti u kategorije ovisno o tome jesu li energične/mirne ili sretne/tužne. Ovakva klasifikacija je korisna u aplikacijama koje nude mogućnost kreiranja playlista, automatske preporuke na temelju sličnosti ugođaja ili značajki pjesama ili pak imaju potrebu za sortiranjem pjesama po ugođaju. Više o ovakvoj klasifikaciji možete pročitati u [1].

Dodatno, osim same klasifikacije pjesama u navedene svrhe, očekujemo da ćemo kroz ovaj projekt moći donijeti i niz zaključaka i opažanja o pjesmama i zvučnim zapisima općenito, pošto ćemo promatrati razne attribute poput akustičnosti, plesnosti i sličnih te komentirati i proučavati koliko su ti atributi značajni kod pjesama.

# 2 Cilj i hipoteze istraživanja

Pomoću *spotipy* biblioteke prikupit ćemo podatke o određenim značajkama pjesama (akustičnost, plesnost, instrumentalnost, glasnoća, tempo, ...). Korištenjem kategorizacijskih tehnika strojnog učenja prikupljene pjesme ćemo kategorizirati po energičnosti (energične/mirne) i stresu (sretne/tužne).

Dakle, podatke koje dobijemo koristeći Spotify-jev API koristimo kao značajke, pjesme trebamo klasificirati, a moguće labele će biti 'energična', 'mirna', 'sretna' ili 'tužna'.

Naš cilj je stoga razviti model za klasifikaciju pjesama prema prethodno navedenim labelama. Hipoteza nam je da je dovoljno koristiti sljedeće attribute koji su dostupni za sve pjesme na Spotifyju: *acousticness*, *danceability*, *energy*, *instrumentalness*, *liveness*, *loudness*, *speechiness*, *valence*, *tempo*. U slučaju da nam ti atributi ne budu dovoljni, koristit ćemo i informacije o popularnosti pjesme, žanru, razdoblju u kojem je nastala.

## 2.1 Zašto baš ovakva klasifikacija?

Ovakav model je poznat pod imenom *Thayerov model* (prema psihologu Robertu Thayeru). Thayer je raspoloženja podijelio s obzirom na energičnost (energičnost/smirenost) i stres (sreća/tuga ili sreća/anksioznost).

Osim ekstrema (sreća, tuga, energičnost, smirenost), Thayer spominje i raspoloženja dobivena kombinacijom određene količine energičnosti i stresa. Tako je zadovoljstvo klasificirao kao kombinaciju niskog stresa i niske energičnosti, veselje kao kombinaciju niskog stresa i visoke energičnosti, anksioznost visokog stresa i visoke energičnosti te depresivnost kao kombinaciju visokog stresa i niske energičnosti.

Mi ćemo za lebele koristiti samo ekstreme ove podjele: energično, mirno, sretno, tužno.

## 3 Pregled dosadašnjih istraživanja

Za motivaciju koristimo članak [2] u kojem se pjesme klasificiraju pomoću neuronske mreže s 10 značajki, jednim slojem s 8 čvorova i 4 izlaznih čvorova (svaki za jednu labelu).

Sličan pristup je opisan i u [4]. U ovom primjeru autor bira između neuronske mreže i random foresta. Ispostavlja se da pristup s neuronskom mrežom daje veću preciznost.

Glavni problem na koji autor iz [2] nailazi je klasifikacija energičnih i sretnih pjesama, što se vidi iz njegove konfuzijske matrice. Ovaj problem smo primijetili i u [5].

Analizom modela pokušat ćemo povećati preciznost kod energičnih i sretnih pjesama i po potrebi istražiti neke dodatne značajke (npr. razdoblje u kojem je pjesma nastala).

## 4 Dataset i metodologija

### 4.1 Dataset

Sakupili smo po više od 10 playlisti za svaku labelu, posebno za vokalnu i posebno za instrumentalnu glazbu. Ukupno imamo 6437 vokalnih pjesama

koje su distribuirane na sljedeći način:

- energične - 1587 pjesama
- mirne - 1683 pjesme
- sretne - 1629 pjesama
- tužne - 1538 pjesme

Što se tiče instrumentalnih pjesama, njih je ukupno 5077 i distribuirane su na sljedeći način:

- energične - 1711 pjesama
- mirne - 1073 pjesme
- sretne - 1259 pjesama
- tužne - 1034 pjesme

Vidimo da su pjesme poprilično uniformno raspoređene osim većeg broja energičnih instrumentalnih pjesama, što je možda i bolje jer za njih znamo da mogu biti problematične za klasificirati.

Pouzdamo se u točnost klasifikacije prikupljenih pjesama na temelju popularnosti i broju like-ova playlisti. Pretpostavljamo da playliste koje smo odabrali ne bi bile popularne i ne bi imale velik broj like-ova da pjesme koje su na njima ne odgovaraju ugođaju koji bi playlista trebala predstavljati. Također, samom kvantitetom podataka smanjujemo utjecaj subjektivnog doživljaja ugođaja.

Kombinirali smo veći broj autora playlisti kako bismo eliminirali potencijalne jake preference u odnosu na žanrove, razdoblja, izvođače, popularnost i sl. Moguće je da se poneke pjesme pojavljuju više puta u različitim playlistama, te se iz tog razloga nismo unaprijed ograničili na neki fiksni broj pjesama za svaku labelu. Cilj nam je bio odabrati dovoljno velik skup pjesama koji ćemo onda moći pročistiti te smanjiti tako da obuhvatimo one pjesme koje su pogodne za treniranje modela.

Više o samom datasetu, kao i konkretne playliste, bit će izneseno kroz eksploratornu analizu dataseta.

Nakon pročišćavanja, dobili smo sljedeću distribuciju za vokalne pjesme:

- energične - 1239 pjesama
- mirne - 1130 pjesama
- sretne - 1101 pjesma
- tužne - 766 pjesama

te za instrumentalne pjesme:

- energične - 1683 pjesme
- mirne - 943 pjesme
- sretne - 1125 pjesama
- tužne - 875 pjesama

Za usporedbu, u članku [2] je korišteno samo 200 pjesama za svaku labelu, pri čemu oni nisu razvijali posebne modele za vokalne i instrumentalne pjesme.

## 4.2 Metodologija

Korisit ćemo već spomenutu biblioteku *Spotipy* ([3]) koja nam omogućava prikupljanje numeričih vrijednosti značajki za pjesme koje ćemo koristiti kao dataset.

Modele ćemo trenirati unakrsnom validacijom i rezultate testiranja analizirati pomoću konfuzijske matrice (posebnu pažnju ćemo obratiti na energične pjesme).

Za početak planiramo koristiti slične značajke kao u [2]. Ako ne postignemo željenu preciznost (u spomenutom članku se postiže preciznost od 76%), istražiti ćemo modele s dodatnim značajkama. Kao dodatne značajke možemo koristiti žanr pjesme, popularnost, razdoblje u kojem je pjesma

nastala. Sve te informacije također možemo dobiti kroz Spotifyjev API i bibliotaku Spotipy.

Glavni pristup će nam biti neuronska mreža sa značajkama, prikupljenim uz pomoć spotipy-ja, kao inputom i 4 outputa (jedan za svaku labelu).

## 5 Literatura

- [1] Nuzzolo, M., Music Mood Classification [Internet], raspoloživo na: <https://sites.tufts.edu/eeseniordesignhandbook/2015/music-mood-classification/>, [28.04.2022.]
- [2] Vaes, C., (2020), Predicting the Music Mood of a Song with Deep Learning [Internet], raspoloživo na: <https://towardsdatascience.com/predicting-the-music-mood-of-a-song-with-deep-learning-c3ac2b45229e>, [28.04.2022.]
- [3] Spotipy <https://spotipy.readthedocs.io/en/2.13.0/>
- [4] Wallach, J., Corr, B., Moschittom, M., (2021), Deep Learning and Music: Mood Classification of Spotify Songs [Internet], raspoloživo na: <https://mikemoschitto.medium.com/deep-learning-and-music-mood-classification-of-spotify-songs-b2dda2bf455>, [28.04.2022.]
- [5] Singh, K., (2021), Music Mood Classification using Neural Networks and Spotify's Web API [Internet], raspoloživo na: <https://medium.com/codex/music-mood-classification-using-neural-networks-and-spotifys-web-api-d73b391044a4>, [28.04.2022.]